

DESCRIPCIÓN DE FUENTES DE DATOS
Modelo de Predicción de Retrasos en Transporte Masivo

Danna Camila Guerra Rincon

Facultad de Ingeniería – Ingeniería en Ciencia de Datos

Corporación Universitaria Iberoamericana

20042026: Inteligencia Artificial

Ing. Joaquín Sánchez

Mayo de 2026

1. Introducción

El presente documento describe las fuentes de datos utilizadas para el desarrollo del modelo de aprendizaje supervisado enfocado en la predicción de retrasos en un sistema de transporte masivo urbano. Dado que no se identificaron fuentes de datos abiertas con la granularidad requerida para el contexto del proyecto, se procedió a construir un dataset sintético representativo basado en variables operativas reales de sistemas de transporte masivo tipo BRT y Metro.

2. Origen y Justificación del Dataset

El dataset fue generado de forma sintética siguiendo patrones empíricos documentados en la literatura de transporte urbano. Las variables y sus rangos de valores fueron definidos con base en las siguientes referencias y consideraciones:

- Patrones de demanda por hora pico (mañana: 6-9h, tarde: 17-19h) y hora valle (10-14h).
- Relación entre porcentaje de ocupación y probabilidad de retraso operativo.
- Efecto de condiciones climáticas (lluvia) sobre la velocidad de circulación y embarque.
- Impacto de eventos especiales (conciertos, partidos, ferias) en la afluencia de pasajeros.
- Variabilidad del retraso según la línea de servicio y la distancia del trayecto.

3. Descripción del Archivo: dataset_transporte.csv

El archivo **dataset_transporte.csv** contiene 100 registros y 14 columnas. Cada fila representa un viaje individual dentro del sistema de transporte masivo.

Variable	Tipo	Rango / Valores	Descripción
id_viaje	Entero	1 – 100	Identificador único del viaje
hora_dia	Entero	6 – 19	Hora de salida (formato 24h)
dia_semana	Entero	1 – 7	Día de la semana (1=Lunes)
linea	Entero	1, 2, 3	Línea de transporte
estacion_origen	Entero	1 – 10	Código de estación de origen
estacion_destino	Entero	3 – 15	Código de estación de destino

distancia_km	Decimal	2.8 – 10.3	Distancia total del trayecto (km)
tiempo_viaje_min	Entero	11 – 39	Tiempo estimado de viaje (min)
ocupacion_porc	Entero	38 – 98	Porcentaje de ocupación del vehículo
temperatura_c	Entero	18 – 28	Temperatura ambiente (°C)
lluvia	Binario	0 = No / 1 = Sí	Condición de lluvia durante el viaje
evento_especial	Binario	0 = No / 1 = Sí	Evento masivo en la ciudad
retraso_min	Entero	0 – 22	Minutos de retraso observados
clasificacion_retraso	Categorico	Ninguno/Bajo/Medio/Alto	Variable objetivo (target)

Tabla 1. Descripción de variables del dataset.

4. Criterio de Clasificación del Retraso (Variable Objetivo)

La variable *clasificacion_retraso* fue construida a partir de la variable numérica *retraso_min* aplicando el siguiente criterio de discretización:

Clase	Rango de Retraso	Descripción Operativa
Ninguno	0 minutos	El vehículo llegó en horario o con adelanto.
Bajo	1 – 3 minutos	Retraso leve, dentro de tolerancia operativa.
Medio	4 – 9 minutos	Retraso moderado, puede afectar transbordos.
Alto	10+ minutos	Retraso severo, requiere intervención operativa.

Tabla 2. Criterio de clasificación de la variable objetivo.

5. Estadísticas Descriptivas Clave

Variable	Min	Media	Mediana	Max	Std
hora_dia	6	12.95	13.00	19	4.47
ocupacion_porc	38%	73.44%	80.00%	98%	19.21
retraso_min	0	6.13	4.00	22	6.33
distancia_km	2.8	6.16	5.85	10.3	1.86
temperatura_c	18°C	22.5°C	22°C	28°C	2.95

Tabla 3. Estadísticas descriptivas de las variables numéricas principales.

El dataset presenta un balance razonable entre clases: Alto (35%), Medio (23%), Bajo (22%) y Ninguno (20%), lo que facilita el entrenamiento de un modelo de clasificación multiclase sin necesidad de técnicas de balanceo como SMOTE.

6. Limitaciones del Dataset

- El dataset es sintético; los patrones fueron diseñados para ser representativos pero no reflejan datos operativos reales de ningún sistema específico.
 - El tamaño de la muestra (100 registros) es reducido para producción. En un escenario real se esperarían miles de registros por día.
 - No se incluyen variables de infraestructura (fallas mecánicas, estado de vías) ni datos externos (accidentes de tráfico) por simplicidad del modelo.
 - La variabilidad entre líneas y estaciones es simplificada y no modela topologías de red complejas.
-

